Interpretabilidad y ética del prototipo

Miguel Ángel Brito Espejo · Grupo 5 · Maestría en Inteligencia Artificial
Bistec LLC · SingulariDev · Tarea 7
13 de octubre de 2026 · Análisis exploratorio sobre datos de desarrollo

Resumen en 30 segundos

- **El ranking no mide relevancia.** En el caso real, el orden de las ideas lo decidieron segundos de diferencia en la hora de publicación.
- **Los grupos mezclan tema y formato.** Un filtro manual anti-cripto y la presencia de enlaces pesan más que muchas palabras del tema.
- **Riesgo principal.** Una puntuación de 95 sobre 100 inspira una confianza que no merece.
- **Ajuste prioritario.** Medir la afinidad por significado, sin el término de búsqueda, y retirar la recencia hasta tener varios días de datos.

1. Modelo evaluado

Objetivo. El prototipo me ayuda, como operador editorial de SingulariDev, a elegir qué videos en inglés preparar para emprendedores que empiezan con agentes de IA. Agrupa publicaciones de X por tema y ordena los grupos; un asistente redacta la ficha y yo decido. Analicé las dos piezas que deciden qué veo primero.

Pieza	Cómo funciona	Qué decide
Agrupamiento K-means, 5 grupos	Qwen3-Embedding convierte cada publicación en un vector, UMAP lo resume y K-means forma cinco grupos	Qué temas existen
Ranking editorial	Puntúa cada grupo de 0 a 100. Afinidad con el enfoque 60 %, diversidad de autores 25 % y recencia 15 %	Qué tema aparece primero

Datos. 79 publicaciones de desarrollo de 74 autores, tomadas de X en 25 minutos, solo en inglés. El análisis reproduce exactamente los grupos y puntuaciones guardados (94,67, 91,15 y 90,97), así que explica el modelo real.

2. Análisis de interpretabilidad

Pregunta	Técnica	Confiabilidad
¿Qué separa los grupos en general?	SHAP sobre un modelo sustituto, una regresión logística con 103 palabras y 6 rasgos de formato	Aproximada. Imita el agrupamiento en 62 % de los casos; el azar daría 25 %
¿Por qué un texto cae en su grupo?	LIME sobre el pipeline real, con 500 variaciones del texto	Moderada. Ajuste local R^2 de 0,45 a 0,60
¿Por qué un grupo queda primero?	Valores de Shapley exactos	Exacta, porque la fórmula es lineal

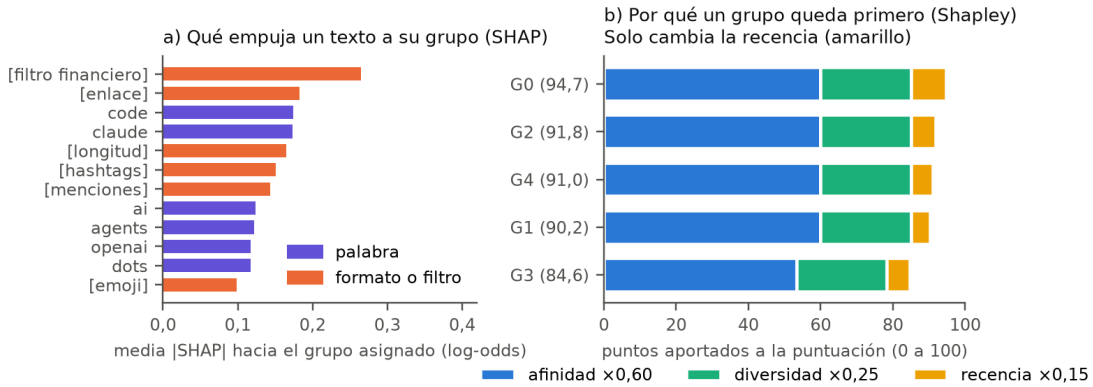


Figura 1. Cómo leerla. a) Cuanto más larga la barra, más empuja ese rasgo a un texto hacia su grupo. Naranja indica formato o filtro, no tema. b) Cada barra es un grupo y cada color, los puntos que aporta un criterio. Enfoque real: "agent, automation, coding, claude".

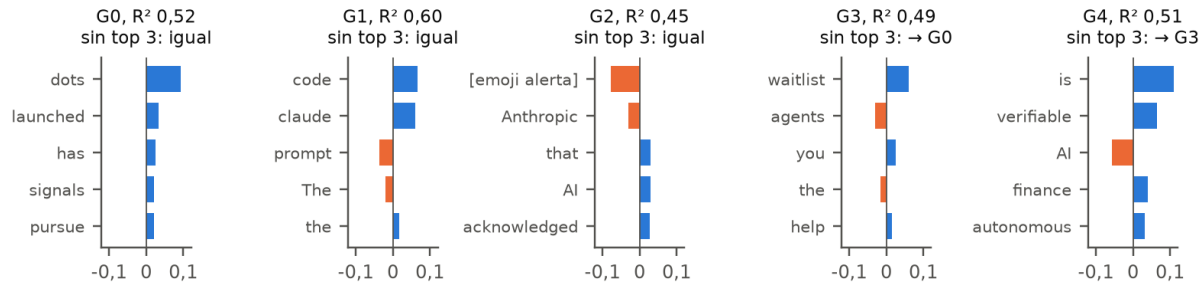


Figura 2. Cómo leerla. Palabras del texto más típico de cada grupo. Azul lo acerca a su grupo y naranja lo aleja. "→ G0" significa que, al borrar sus tres palabras azules, el texto cambia al grupo G0.

Patrones observados.

- Tres grupos tienen un tema claro. G0 reúne noticias de Dots, de OpenAI; G1, conversaciones sobre Claude Code; G4, finanzas y ejecución verificable.
- G3 funciona como cajón de sastre. Su rasgo más fuerte apenas pesa 0,07.
- Las asignaciones son frágiles. Dos de cinco textos cambian de grupo al borrar tres palabras, y en G4 la palabra decisiva es "is".

Coherencia con el problema. Parcial. Los temas claros, como Claude Code, sí interesan a la audiencia de SingulariDev. Pero el modelo también agrupa por estilo y el ranking no refleja valor editorial.

3. Riesgos éticos

Base: principios del curso de transparencia y rendición de cuentas (IEEE, 2022), equidad (UNESCO, 2023) y privacidad (Corrêa et al., 2023).

Riesgo	Evidencia	Impacto posible	Principio
Falsa precisión	95 sobre 100 decidido por segundos	Elijo un tema por la hora de publicación creyendo que es el mejor	Transparencia
Sesgo circular	"agent", el término de búsqueda, aparece en 83 % de los textos	El sistema confirma lo que ya buscaba y oculta temas vecinos	Rendición de cuentas
Exclusión silenciosa	El filtro elimina 12 de 17 textos de G4, incluido "ransomware"	Desaparece un tema de seguridad útil para la audiencia, sin aviso	Transparencia
Proxies de formato	El formato explica 19 % de la importancia	Pesan más las cuentas de noticias y promoción; otros estilos y otros idiomas quedan fuera	Equidad
Agenda de proveedores	"claude", "openai" y "dots" definen grupos	Videos que amplifican anuncios comerciales sin verificar	Responsabilidad
Uso indebido	Muestra de 25 minutos	Tomar el ranking como predicción de tendencias o ventas	Uso apropiado
Privacidad	Textos de terceros enviados al LLM	Exposición de autores que no consintieron este uso	Privacidad

4. Hallazgos clave

Variable	Dirección y magnitud	Qué significa
Recencia, peso 15 %	Decide el orden. G0 gana por 290 s de diferencia media; los puestos 2 a 4 se separan por 81 y 74 s, menos de 1 punto	El primer lugar es el grupo más fresco, no el más relevante
Afinidad, peso 60 %	Saturada: vale 1 en los cuatro primeros. Sin "agent", los tres primeros pasan a ser G1, G3 y G0	Mide el término de búsqueda, no el enfoque
Diversidad, peso 25 %	Aporte nulo, Shapley 0. Todos los grupos superan el tope de cinco autores	Un cuarto de la fórmula no aporta información
Filtro financiero	Rasgo más fuerte del agrupamiento, 0,26; define G4	Una regla manual da forma a los temas
Formato: enlace, hashtags, menciones, emoji y longitud	19 % de la importancia. Un emoji de alerta aleja un texto de G2	Los grupos mezclan tema y estilo

Variable	Dirección y magnitud	Qué significa
Palabras de tema: "code", "claude", "openai"	Empujan con fuerza hacia G1 y G0	Aquí el modelo sí capta temas útiles

También probé 171 combinaciones de pesos y G0 ganó en todas. Eso no demuestra robustez. Pasa porque dos de los tres criterios no varían entre grupos.

5. Estrategias de mitigación

- **Ajustes técnicos.** Mostrar en la interfaz el desglose de cada puntuación y declarar empate si la diferencia es menor de 3 puntos.
- **Datos y variables.** Registrar el término de búsqueda y avisar cuando un término del enfoque aparezca en más de la mitad de los textos. Mostrar cuántos textos excluye el filtro en cada grupo.
- **Uso responsable.** Exigir una fuente primaria antes de aceptar una ficha sobre un producto. Presentar el ranking como apoyo de lectura, no como predicción. Mantener la aprobación humana y los datos de autores en local.
- **Límites explícitos.** 25 minutos de datos, solo inglés y 74 autores. SHAP aproximado al 62 % y LIME con R^2 de 0,60 como máximo. El sistema no mide crecimiento, novedad ni conversión.

6. Aprendizajes derivados del análisis

Supuesto inicial	Qué mostró el análisis	Veredicto
Los grupos son temas	Tres temas claros, un cajón de sastre y peso del formato	Confirmado a medias
La puntuación mide relevancia	Mide frescura y repite el término de búsqueda	Refutado
Ajustar los pesos mejora el ranking, como pidió el Comité	Los pesos casi no importan si los criterios están saturados	Cuestionado. Hay que cambiar las señales, no los pesos

Qué cambia en la práctica. El valor del sistema está en organizar fuentes y acelerar la redacción, no en decidir qué tema importa. Esa decisión sigue siendo mía, y el sistema debe mostrar por qué ordena como ordena. También aprendí a no fiarme de una sola técnica. SHAP por sí solo habría ocultado la fragilidad que LIME reveló.

7. Propuestas de ajuste al modelo

Evidencia	Ajuste	Cómo sabré que funcionó
"agent" cubre 83 % y satura la afinidad	Quitar los términos de búsqueda y medir afinidad por similitud semántica con el enfoque	Ningún término supera 50 % y el orden cambia con enfoques distintos
Diversidad con Shapley 0	Contar autores distintos por publicación, sin tope de cinco	El criterio varía entre grupos
Recencia decide por 74 a 290 s	Retirarla hasta tener siete días de datos y medir crecimiento entre ventanas	Empates declarados y diferencias con intervalo
El formato pesa 19 %	Quitar enlaces, menciones, emoji y hashtags antes del embedding	Menos peso SHAP del formato, con silueta y ARI en un corte nuevo
El filtro elimina 71 % de G4	Convertir la exclusión en etiqueta visible y sacar "ransomware" de la lista	Exclusiones visibles por grupo
G3 difuso y textos que cambian de grupo	Mostrar la probabilidad de asignación y marcar las menores de 0,4	Prueba de borrado repetida en cada versión

Referencias: Corrêa, N. K., et al. (2023). Worldwide AI ethics. Patterns, 4(10), 100857. IEEE (2022). Ethically Aligned Design, 2.ª ed. UNESCO (2023). Ethics of Artificial Intelligence in Education. Lundberg y Lee (2017), SHAP. Ribeiro et al. (2016), LIME. Código y resultados: interpretabilidad.py e interpretabilidad-tarea7.json en el repositorio del prototipo.